


제3장 중선형회귀모형

3.8 기타논제

3.8.3 최소제곱법의 기하학적 의미

최소제곱법을 이용하여 회귀계수를 추정하는 과정은 기하학적으로 더욱 쉽고 명료하게 설명될 수 있다.



중회귀모형 $y = X\beta + \epsilon$ 여기서, $X_{(n \times p)}$

■ 반응변수의 관측값 벡터 $y = [y_1 \cdots y_n]^t$: n 차원 공간의 한 점

$$\text{■ } X\beta = \begin{bmatrix} X_0 & X_1 & \cdots & X_{p-1} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{bmatrix} = \beta_0 X_0 + \beta_1 X_1 + \cdots + \beta_{p-1} X_{p-1}$$

■ 만약 X 의 계수(rank)가 p 라면 $X\beta$ 는 β 의 값이 변함에 따라 n 차원 공간에서 p 개의 선형독립인 벡터 $[X_0 \ X_1 \ \cdots \ X_{p-1}]$ 에 의해 생성(span)되는 p 차원 평면[→추정공간 (estimation space)]을 형성하게 된다.

■ 오차벡터 $\epsilon = [\epsilon_1 \ \epsilon_2 \ \cdots \ \epsilon_n]^t$

: 이 추상공간 위의 한 점과 벡터 y 와의 차이를 나타내는 벡터

■ 최소제곱법: 오차제곱합 $S = \epsilon^t \epsilon = (y - X\beta)^t (y - X\beta)$ 을 최소화하는 β 의 값을 찾는 것
 → 벡터 y 에서 가장 가까운 추정공간 위의 한 점을 찾는 것
 → 이 점은 벡터 y 를 추정공간에 정사영(orthogonal projection)시켜 얻을 수 있으며,
 이 점을 $\hat{y} = X\hat{\beta}$ 라 하면 여기에 해당되는 벡터 $\hat{\beta}$ 가 β 의 최소제곱추정치가 된다.

■ 잔차벡터 $e = y - X\hat{\beta}$ 는 추정공간 위의 모든 벡터들과 직교한다.

$$X \text{의 모든 열벡터에 대해 } X_j^t e = X_j^t (y - X\hat{\beta}) = 0 \quad (j = 0, 1, \dots, p-1)$$

$$\rightarrow X^t e = X^t y - X^t X\hat{\beta} = 0 \Rightarrow (\text{정규방정식}) X^t X\hat{\beta} = X^t y$$

■ 회귀의 분산분석에 사용되는 세 가지 제곱합의 분할은 직각삼각형에 대한 피타고라스 정리를 사용하여 얻어진다.

- 잔차벡터 e 와 \hat{y} 이 직교 $\rightarrow \|y\|^2 = \|\hat{y}\|^2 + \|e\|^2$
- 벡터의 내적으로 표현 $\rightarrow y^t y = \hat{y}^t \hat{y} + (y - X\hat{\beta})^t (y - X\hat{\beta}) \leftarrow SST = SSR + SSE$
- 자유도 간의 관계식 $n = p + (n - p)$: 각 벡터가 위치하는 공간의 차원 간의 관계

3.8.4 다변량 정규분포와의 관계

$$Z \sim N_n(\mu, \Sigma)$$

$$Z = \begin{bmatrix} Z_1 & Z_2 \end{bmatrix}^t, \mu = \begin{bmatrix} \mu_1 & \mu_2 \end{bmatrix}, \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

$$\rightarrow Z_1 | Z_2 \sim N_r(\mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (Z_2 - \mu_2), \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21})$$

$$y = \beta_0 + \beta_1 X_1 + \dots + \beta_{p-1} X_{p-1} + \epsilon$$

$$E(Y|X) = \beta_0 + \beta_1 X_1 + \dots + \beta_{p-1} X_{p-1}$$

$$= \beta_0 + [\beta_1 \dots \beta_{p-1}]^t X \quad \text{여기서, } X = \begin{bmatrix} X_1 & \dots & X_{p-1} \end{bmatrix}$$

$$= E(Y) + Cov(Y, X) Cov(X)^{-1} [X - E(X)] \leftarrow \text{다변량 정규분포의 조건부 기댓값}$$

$$= E(Y) - Cov(Y, X) Cov(X)^{-1} E(X) + Cov(Y, X) Cov(X)^{-1} X$$

$$\Rightarrow \beta_0 = E(Y) - Cov(Y, X) Cov(X)^{-1} E(X)$$

$$[\beta_1 \dots \beta_{p-1}]^t = Cov(Y, X) Cov(X)^{-1}$$

$p = 2$ 인 단순선형회귀모형의 경우를 생각해 보면

모집단	표본
$\beta_0 = E(Y) - \frac{Cov(Y, X)E(X)}{Var(X)}$	$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$
$\beta_1 = \frac{Cov(Y, X)}{Var(X)}$	$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$