

## 4. 분산의 신뢰구간

<정리 6.4-1>  $X_1, X_2, \dots, X_n$ 을 정규분포  $N(\mu, \sigma^2)$ 으로부터 추출한 확률표본이라고 할 때, 평균  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 와 분산

$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  사이에는 다음의 성질이 성립한다.

(1)  $\bar{X}$ 와  $S^2$ 은 서로 독립이다.

(2)  $\frac{nS^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2}$ 는 자유도가  $n-1$ 인 카이제곱분포  $\chi^2(n-1)$ 를 따른다.

<증명> (1) By Basu 정리

<Basu 정리> 통계량  $T$ 와  $\theta$ 의 완비충분 통계량이고  $Y = Y(\theta)$ 와 독립이면  $T$ 와  $Y$ 를  $\theta$ 에 대하여 서로 독립이다.

<충분통계량(6.6절)>  $X_1, X_2, \dots, X_n$ : 모수가  $\theta$ 인 분포에서의 확률표본,  $T = g(X_1, X_2, \dots, X_n)$ 은  $\theta$ 의 추정량이라고 하자.  $T=t$ 가 주어졌을 때, 확률  $P[X_1 = x_1, \dots, X_n = x_n | T=t]$ 가  $\theta$ 와 무관한 경우에 통계량  $T$ 는  $\theta$ 의 충분통계량이라고 한다.

• 통계량 조건부분포가 모수  $\theta$ 에 의존하지 않는다는 것은 통계량  $T$ 가 이미  $\theta$ 에 대한 모든 정보를 설명하고 있기 때문에,  $T$ 가 주어지고 나머지 정보( $n$ 개의 표본)는  $\theta$ 를 설명하는 데 아무런 도움을 주지 못한다는 뜻이다.

<완비성>  $X_1, X_2, \dots, X_n$ : 모수가  $\theta$ 인 분포에서의 확률표본,  $T = g(X_1, X_2, \dots, X_n)$ 에 대하여,  $E(\varphi(T)) = 0$ 을 만족하는  $\theta$ 에 무관한 함수  $\varphi$ 가  $\varphi(\cdot) = 0$ 뿐이라면,  $T$ 를 완비통계량이라고 한다. 만약  $T$ 가  $\theta$ 에 대한 충분통계량이라면, 이를 완비 충분통계량이라 한다.

$$(2) \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 = \sum_{i=1}^n \left( \frac{X_i - \bar{X} + \bar{X} - \mu}{\sigma} \right)^2 = \sum_{i=1}^n \left( \frac{X_i - \bar{X}}{\sigma} \right)^2 + \frac{n(\bar{X} - \mu)^2}{\sigma^2} \dots (*)$$

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}: \text{표준정규분포 } N(0, 1) \text{을 따름} \Rightarrow Z^2 = \frac{n(\bar{X} - \mu)^2}{\sigma^2}: \chi^2(1) \text{을 따름}$$

식(\*)에서  $W := \frac{nS^2}{\sigma^2} + Z^2$ 라 하면  $\bar{X}$ 와  $S^2$ 은 (1)에 의하여 서로 독립  $\Rightarrow S^2$ 와  $Z^2$  역시 독립.

$$\bullet W \text{의 적률생성함수: } E[e^{tW}] = E\left[e^{t\left(\frac{nS^2}{\sigma^2} + Z^2\right)}\right] = E[e^{t(nS^2/\sigma^2)}] \cdot E[e^{tZ^2}].$$

$$\bullet W \text{의 분포는 } \chi^2(n) \text{이므로 적률생성함수: } E[e^{tW}] = (1-2t)^{-\frac{n}{2}}$$

$$Z^2 \text{의 분포는 } \chi^2(1) \text{이므로 적률생성함수: } E[e^{tZ^2}] = (1-2t)^{-\frac{1}{2}}$$

$$E[e^{t(nS^2/\sigma^2)}] = E[e^{tW}] / E[e^{tZ^2}] = (1-2t)^{-\frac{n-1}{2}}, t < \frac{1}{2}.$$

$\therefore \frac{nS^2}{\sigma^2}$ 의 분포는 자유도가  $n-1$ 인 카이제곱분포  $\chi^2(n-1)$ 를 따른다.

• 단일 모집단의 경우  $\sigma^2$ 의 신뢰구간:  $\frac{nS^2}{\sigma^2} \sim \chi^2(n-1)$ 이므로

$$P\left[\chi^2_{1-\frac{\alpha}{2}}(n-1) \leq \frac{nS^2}{\sigma^2} \leq \chi^2_{\frac{\alpha}{2}}(n-1)\right] = 1-\alpha.$$

$$\therefore \sigma^2 \text{의 } 100(1-\alpha)\% \text{ 신뢰구간: } \left[ \frac{nS^2}{\chi^2_{\frac{\alpha}{2}}(n-1)}, \frac{nS^2}{\chi^2_{1-\frac{\alpha}{2}}(n-1)} \right]$$

<정의 6.4-1>  $U$ 와  $V$ 가 서로 독립이고 각각 자유도가  $r_1, r_2$ 인 카이제곱분포를 따를 때,

$$F = \frac{U/r_1}{V/r_2}$$

는 분자의 자유도가  $r_1$ , 분모의 자유도가  $r_2$ 인 F-분포((F-distribution 또는 Fisher-Snedecor distribution; 분산분석 등에 널리 사용)를 따른다.

• F-분포의 밀도함수

$$f(x) = \frac{\Gamma\left(\frac{r_1+r_2}{2}\right)\left(\frac{r_1}{r_2}\right)^{\frac{r_1}{2}} x^{\frac{r_1}{2}-1}}{\Gamma\left(\frac{r_1}{2}\right)\Gamma\left(\frac{r_2}{2}\right)\left(1+\frac{r_1}{r_2}x\right)^{\frac{r_1+r_2}{2}}}, \quad 0 < x < \infty.$$

<정리 6.4-2> F-분포의 평균과 분산

$$E(F) = \frac{r_2}{r_2-2}, \quad \text{Var}(F) = \frac{2r_2^2(r_1+r_2-2)}{r_1(r_2-2)^2(r_2-4)}$$

<증명> 자유도  $r$ 인 카이제곱분포  $\chi^2(r)$ 의 밀도함수와 평균, 분산, 적률생성함수

$$f(x) = \frac{1}{\Gamma\left(\frac{r}{2}\right)2^{\frac{r}{2}}} x^{\frac{r}{2}-1} e^{-\frac{x}{2}}, \quad 0 \leq x < \infty.$$

$$\mu = r, \quad \sigma^2 = 2r, \quad M(t) = (1-2t)^{-\frac{r}{2}}.$$

$$\bullet E\left(\frac{U}{r_1}\right) = \frac{1}{r_1} E(U) = \frac{1}{r_1} \cdot r_1 = 1, \quad E(U^2) = (E(U))^2 + 2r_1 = r_1^2 + 2r_1$$

$$\bullet E\left(\frac{1}{V}\right) = \int_0^\infty \frac{1}{x} \cdot \frac{1}{\Gamma\left(\frac{r_2}{2}\right)2^{\frac{r_2}{2}}} x^{\frac{r_2}{2}-1} e^{-\frac{x}{2}} dx$$

$$= \frac{\Gamma\left(\frac{r_2}{2}-1\right)}{2\Gamma\left(\frac{r_2}{2}\right)} \int_0^\infty \frac{1}{\Gamma\left(\frac{r_2}{2}-1\right)2^{\frac{r_2}{2}-1}} x^{\left(\frac{r_2}{2}-1\right)-1} e^{-\frac{x}{2}} dx = \frac{1}{2\left(\frac{r_2}{2}-1\right)} = \frac{1}{r_2-2}.$$

$$\bullet E\left(\frac{1}{V^2}\right) = \int_0^\infty \frac{1}{x^2} \cdot \frac{1}{\Gamma\left(\frac{r_2}{2}\right)2^{\frac{r_2}{2}}} x^{\frac{r_2}{2}-1} e^{-\frac{x}{2}} dx$$

$$= \frac{\Gamma\left(\frac{r_2}{2}-2\right)}{2^2\Gamma\left(\frac{r_2}{2}\right)} \int_0^\infty \frac{1}{\Gamma\left(\frac{r_2}{2}-2\right)2^{\frac{r_2}{2}-2}} x^{\left(\frac{r_2}{2}-2\right)-1} e^{-\frac{x}{2}} dx$$

$$= \frac{1}{4\left(\frac{r_2}{2}-1\right)\left(\frac{r_2}{2}-2\right)} = \frac{1}{(r_2-2)(r_2-4)}.$$

∴ F-통계량의 평균과 2차 적률 및 분산

$$E(F) = E\left(\frac{U/r_1}{V/r_2}\right) = E\left(\frac{U}{r_1}\right) \cdot E\left(\frac{r_2}{V}\right) = \frac{r_2}{r_2-2}.$$

$$E(F) = E\left[\left(\frac{U}{r_1}\right)^2\right] \cdot E\left[\left(\frac{r_2}{V}\right)^2\right] = \frac{(r_1^2+2r_1)}{r_1^2} \cdot \frac{r_2^2}{(r_2-2)(r_2-4)} = \frac{r_2^2(r_1^2+2r_1)}{r_1^2(r_2-2)(r_2-4)}$$

$$\text{Var}(F) = E(F^2) - (E(F))^2 = \frac{r_2^2(r_1^2+2r_1)}{r_1^2(r_2-2)(r_2-4)} - \frac{r_2^2}{(r_2-2)^2} = \frac{(r_2^2r_1^2+2r_1r_2^2)(r_2-2) - r_2^2(r_1^2(r_2-4))}{r_1^2(r_2-2)^2(r_2-4)} = \frac{2r_2^2(r_1+r_2-2)}{r_1(r_2-2)^2(r_2-4)}$$

## [참고] F-분포의 성질

$$\textcircled{1} F_{1-\alpha/2}(r_1, r_2) = \frac{1}{F_{\alpha/2}(r_2, r_1)}$$

$$\textcircled{2} X_1, X_2, \dots, X_m \sim N(\mu_X, \sigma_X^2)$$

$$Y_1, Y_2, \dots, Y_n \sim N(\mu_Y, \sigma_Y^2)$$

$X_i$ 와  $Y_j$ 는 서로 독립이라고 하자.

- $\frac{nS_Y^2}{\sigma_Y^2} \sim \chi^2(n-1)$ ,  $\frac{nS_X^2}{\sigma_X^2} \sim \chi^2(m-1)$  서로 독립

$$F = \frac{nS_Y^2/\sigma_Y^2(n-1)}{mS_X^2/\sigma_X^2(m-1)} \sim F(n-1, m-1)$$


- 두 모분산의 비율에 대한 신뢰구간

$P[F \leq c] = \frac{\alpha}{2}$ ,  $P[F \leq d] = 1 - \frac{\alpha}{2}$ 를 만족하는  $c$ 와  $d$ 라 하면

$$P[c \leq F \leq d] = P\left[c \cdot \frac{mS_X^2/(m-1)}{nS_Y^2/(n-1)} \leq \frac{\sigma_X^2}{\sigma_Y^2} \leq d \cdot \frac{mS_X^2/(m-1)}{nS_Y^2/(n-1)}\right] = 1 - \alpha.$$

$\therefore \frac{\sigma_X^2}{\sigma_Y^2}$ 의  $100(1-\alpha)\%$  신뢰구간

$$\left[ c \cdot \frac{mS_X^2/(m-1)}{nS_Y^2/(n-1)}, \quad d \cdot \frac{mS_X^2/(m-1)}{nS_Y^2/(n-1)} \right].$$



## 5. 평균의 신뢰구간<모분산을 모르는 경우>

<정의 6.5-1> 확률변수  $Z$ 가 표준정규분포  $N(0, 1)$ 을 따르고, 확률변수  $U$ 는 자유도가  $r$ 인 카이제곱분포  $\chi^2(r)$ 를 따르며  $Z$ 와  $U$ 가 서로 독립일 때, 통계량

$$T = \frac{Z}{\sqrt{U/r}}$$

는 자유도가  $r$ 인 t-분포  $t(r)$ 를 따른다. t-분포의 밀도함수


$$f(x) = \frac{\Gamma\left(\frac{r+1}{2}\right)}{\sqrt{\pi r} \Gamma\left(\frac{r}{2}\right) \left(1 + \frac{x^2}{r}\right)^{\frac{r+1}{2}}}, \quad -\infty < x < \infty.$$

<정리 6.5-1> 자유도가  $r$ 인 t-분포  $t(r)$ 의 통계량  $T$ 의 평균과 분산

$$E(T) = 0, \quad \text{Var}(T) = E(T^2) = \frac{r}{r-2}, \quad r \geq 2.$$

<증명>  $E(T) = E(Z) \cdot E(\sqrt{r/U}) = 0 \cdot E(\sqrt{r/U}) = 0$

$$\text{Var}(T) = E(T^2) - (E(T))^2 = E(Z^2) \cdot E\left(\frac{r}{U}\right) = 1 \cdot r \cdot E\left(\frac{1}{U}\right) = \frac{r}{r-2}.$$



t-분포는 정규분포와 마찬가지로 좌우대칭인 분포이며 정규분포보다 꼬리 부분의 확률 값이 더 크다. 그러나 자유도가 커지면 t-분포는 정규분포와 거의 같게 된다.

자유도( $r$ )가  $\infty$ 이면 t분포는 정규분포와 일치

• 단일 모집단에서 평균의 신뢰구간

$X_1, X_2, \dots, X_n \sim N(\mu, \sigma^2) \Rightarrow \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1), \quad \frac{nS^2}{\sigma^2} \sim \chi^2(n-1)$ 이며 이 둘은 서로 독립

$$T = \frac{\frac{(\bar{X} - \mu)}{\sigma / \sqrt{n}}}{\sqrt{\frac{nS^2}{\sigma^2(n-1)}}} = \frac{\bar{X} - \mu}{S / \sqrt{n-1}} \sim t(n-1)$$

$$\begin{aligned} 1 - \alpha &= P\left[-t_{\alpha/2}(n-1) \leq \frac{\bar{X} - \mu}{S / \sqrt{n-1}} \leq t_{\alpha/2}(n-1)\right] \\ &= P\left[\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n-1}} \leq \mu \leq \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n-1}}\right]. \end{aligned}$$

[참고] ① 신뢰구간  $\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ 의 폭은  $\bar{X} \pm t_{\alpha/2}(n-1) \frac{S}{\sqrt{n-1}}$ 보다 좁다.

②  $\sigma^2$ 을 모르는 경우라도 표본의 크기가 약 30 이상으로 큰 경우에는 통계량  $T$ 의 분포는 근사적으로 표준정규분포에 가깝게 된다.

- 두 모집단에서 평균의 차에 대한 신뢰구간

$X_1, X_2, \dots, X_n \sim N(\mu_X, \sigma_X^2)$ ,  $Y_1, Y_2, \dots, Y_n \sim N(\mu_Y, \sigma_Y^2)$ 이며 두 표본은 서로 독립이고 두 표본의 분산은 같다 ( $\sigma_X^2 = \sigma_Y^2 = \sigma^2$ )고 가정

$$\text{통계량 } U = \frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{\sqrt{\frac{\sigma^2}{m} + \frac{\sigma^2}{n}}} \sim N(0, 1)$$

$$\text{통계량 } V = \frac{mS_X^2}{\sigma^2} + \frac{nS_Y^2}{\sigma^2} \sim \chi^2(m+n-2)$$

$U$ 와  $V$ 는 서로 독립이므로 통계량

$$\begin{aligned} T &= \frac{\frac{[\bar{X} - \bar{Y} - (\mu_X - \mu_Y)]}{\sqrt{\frac{\sigma^2}{m} + \frac{\sigma^2}{n}}}}{\sqrt{\frac{(mS_X^2 + nS_Y^2)}{\sigma^2(m+n-2)}}} \\ &= \frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{\sqrt{[(mS_X^2 + nS_Y^2)/(m+n-2)]\left(\frac{1}{m} + \frac{1}{n}\right)}} = \frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{S_p \sqrt{\left(\frac{1}{m} + \frac{1}{n}\right)}} \end{aligned}$$

$\Rightarrow$  자유도가  $m+n-2$ 인  $t$ -분포  $t(m+n-2)$

여기서  $S_p^2 = \frac{mS_X^2 + nS_Y^2}{m+n-2}$ ; 합동표본분산(Pooled sample variance)

- 두 표본의 평균의 차  $\mu_X - \mu_Y$ 의  $100(1-\alpha)\%$  신뢰구간

$$\begin{aligned} P\left[\bar{X} - \bar{Y} - t_{\alpha/2}(m+n-2)S_p\sqrt{\frac{1}{m} + \frac{1}{n}} \leq \mu_X - \mu_Y \right. \\ \left. \leq \bar{X} - \bar{Y} + t_{\alpha/2}(m+n-2)S_p\sqrt{\frac{1}{m} + \frac{1}{n}}\right] \\ = 1 - \alpha. \end{aligned}$$

[참고] 표본의 크기가 클 때,  $\mu_X - \mu_Y$ 의  $100(1-\alpha)\%$  신뢰구간

$$\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\frac{S_X^2}{m-1} + \frac{S_Y^2}{n-1}}$$

<예 6.5-1> 서로 독립인 두 집단에서 자료를 얻어 정리한 결과가 다음과 같다고 하자. 평균의 차에 대한 95% 신뢰구간을 구하라.

$$\text{집단 1 : } m = 15, \quad \bar{X} = 781.31, \quad s_X^2 = 60.76,$$

$$\text{집단 2 : } n = 9, \quad \bar{Y} = 78.61, \quad s_Y^2 = 48.24.$$

<풀이>  $\mu_X - \mu_Y$ 의 95% 신뢰구간은 자유도가  $15+9-2=22$ 인  $t$ -분포표에서  $P[T \leq 2.074] = 0.975$ 이므로

$$81.31 - 78.61 \pm 2.074 \sqrt{\frac{9(60.76) + 15(48.24)}{22} \left(\frac{1}{15} + \frac{1}{9}\right)}$$

이다. 즉,  $[-3.95, 9.35]$ 이다.

## 6. 최소분산 불편추정량과 충분통계량

• 좋은 추정량이란 일반적으로 충분성을 갖추고 있고 분산이 작은 통계량

<정의 6.5-1> 최소분산 불편추정량

$X_1, X_2, \dots, X_n$ 은 밀도함수가  $f(x; \theta)$ 인 분포에서의 확률표본이라고 하자. 다음의 두 가지 조건을 만족하는 통계량  $T$ 를  $\theta$ 의 최소분산 불편추정량(Minimum variance unbiased estimator : MVUE)이라고 한다.

(a)  $E(T) = \theta$

(b) 다른 어떠한 불편 추정량  $T'$ 에 대해서도  $Var(T) \leq Var(T')$ .

<예 6.6-1>  $X_1, X_2, X_3$ 를 정규분포  $N(\mu, \sigma^2)$ ,  $-\infty < \mu < \infty$ ,  $\sigma^2 > 0$ 에서의 확률표본이라고 하면 표본평균  $\bar{X}$ 의 기댓값은  $E(\bar{X}) = \mu$ , 분산은  $Var(\bar{X}) = \frac{\sigma^2}{n}$ 이다. 이제  $Y = \frac{X_1 + 2X_2 + 3X_3}{6}$ 이라 두면

Y의 기댓값:  $E(Y) = \frac{1}{6}E(X_1 + 2X_2 + 3X_3) = \frac{1}{6}(\mu + 2\mu + 3\mu) = \mu$ .

Y의 분산:  $Var(Y) = \left(\frac{1}{6}\right)^2 \sigma^2 + \left(\frac{2}{6}\right)^2 \sigma^2 + \left(\frac{3}{6}\right)^2 \sigma^2 = \frac{7}{18} \sigma^2$

$\therefore \bar{X}$ 와 Y는  $\mu$ 의 불편 추정량이며  $Var(\bar{X}) < Var(Y)$ 임을 알 수 있다.

<예 6.6-2>  $X_1, X_2, \dots, X_n$ 을 정규분포  $N(\mu, \sigma^2)$ 에서의 확률표본이라고 하자.

표본분산  $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 으로 두면,  $E\left[\frac{n}{n-1} S^2\right] = \sigma^2$ 이며  $E[(cS^2 - \sigma^2)^2]$ 을 최소로 하는 상수  $c$  ( $cS^2$ 의 형태를

갖는  $\sigma^2$ 의 최소평균 제곱오차 추정량(Minimum mean square error estimator))를 구해보자

<풀이>  $W = cS^2 - \sigma^2$ ,  $E[W^2] = \mu_W^2 + \sigma_W^2$ 이고,

$$E(S^2) = \frac{n-1}{n} \sigma^2, \quad Var(S^2) = \frac{2(n-1)}{n^2} \sigma^4 \text{이므로}$$

$$\begin{aligned} E[(cS^2 - \sigma^2)^2] &= [E(cS^2 - \sigma^2)]^2 + Var(cS^2 - \sigma^2) \\ &= \left[c \frac{n-1}{n} \sigma^2 - \sigma^2\right]^2 + \frac{2c^2(n-1)}{n^2} \sigma^4. \end{aligned}$$

$$\frac{\partial E[(cS^2 - \sigma^2)^2]}{\partial c} = 0 \Rightarrow 2\left[c \frac{n-1}{n} \sigma^2 - \sigma^2\right] \frac{n-1}{n} \sigma^2 + 4c \frac{n-1}{n^2} \sigma^4 = 0$$

$$\therefore c = \frac{n}{n+1}.$$

$\sigma^2$ 의 최소제곱오차 추정량

$$\frac{n}{n+1} S^2 = \frac{1}{n+1} \sum_{i=1}^n (X_i - \bar{X})^2. \text{ [참고]} \quad S^2 \text{은 } \sigma^2 \text{의 최우 추정량이고, } \frac{n}{n-1} S^2 \text{은 } \sigma^2 \text{의 불편 추정량이다.}$$

<예 6.6-3>  $X_1, X_2, \dots, X_n$ 을 정규분포  $N(\mu, \sigma^2)$ 에서의 확률표본이라고 하자.

$cS = c \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$ 이  $\sigma$ 의 불편추정량이 되도록 상수  $c$ 의 값을 구하여라.

<풀이>  $\frac{nS^2}{\sigma^2} \sim \chi^2(n-1)$ ,  $Y = \frac{nS^2}{\sigma^2}$ 라 두면

$$E[\sqrt{Y}] = \int_0^\infty \sqrt{y} \cdot \frac{1}{\Gamma\left(\frac{n-1}{2}\right) 2^{\frac{n-1}{2}}} y^{\frac{n-1}{2}-1} e^{-\frac{y}{2}} dy$$

$$= \frac{\Gamma\left(\frac{n}{2}\right) \sqrt{2}}{\Gamma\left(\frac{n-1}{2}\right)} \int_0^\infty \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}}} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} dy = \frac{\Gamma\left(\frac{n}{2}\right) \sqrt{2}}{\Gamma\left(\frac{n-1}{2}\right)}$$

$$E[S] = E\left[\sqrt{\frac{\sigma^2}{n} \cdot \frac{nS^2}{\sigma^2}}\right] = \frac{\sigma}{\sqrt{n}} E(\sqrt{Y}) = \frac{\sqrt{2}}{\sqrt{n}} \cdot \frac{\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)} \cdot \sigma$$

$$\therefore c = \frac{\sqrt{n}}{\sqrt{2}} \cdot \frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)}$$

※ 라오-블랙웰의 정리(Rao-Blackwell theorem)를 이용하면 보다 간편하게 최소분산 불편추정량을 찾을 수 있다.

<정리 6.6-1> 라오-블랙웰의 정리(Rao-Blackwell theorem)

$U$ 가  $T$ 의 통계량이고  $E(U) = \theta$  (즉,  $U$ 는  $\theta$ 의 불편 추정량)라 하자.  $W = E(U|T)$ 라 두면 다음 식이 성립한다.

(1)  $W$ 는  $T$ 의 함수이다.

(2)  $E(W) = \theta$ .

(3)  $Var(W) \leq Var(U)$ .

<증명> (1)  $W$ 는  $T$ 가 주어졌을 때  $U$ 의 기댓값이므로  $T$ 의 함수가 된다.

(2)  $E(W) = E[E(U|T)] = E(U) = \theta$ , by 95쪽 이중 기댓값 정리  $E(X) = E[E(X|Y)]$

(3)  $Var(U) = E[U - \theta]^2 = E[U - W + W - \theta]^2$

$$= E[U - W]^2 + 2E[(U - W)(W - \theta)] + E[W - \theta]^2$$

$$E[(U - W)(W - \theta)] = E[E[(U - W)(W - \theta)|T]] = (W - \theta)E[(U - W)|T]$$

$$\xrightarrow{E(U|T)=W} (W - \theta)[W - E(W|T)] = 0$$

$$Var(U) = E[U - W]^2 + E[W - \theta]^2 = E[U - W]^2 + Var(W) \geq Var(W)$$

<정의 6.6-2> 충분 통계량 (Sufficient statistic)

$X_1, X_2, \dots, X_n$ 을 모수  $\theta$ 인 분포에서의 확률표본이라 하고  $T = g(X_1, X_2, \dots, X_n)$ 은  $\theta$ 의 추정량이라고 하자.  $T$ 의 값  $T = t$ 가 주어졌을 때, 확률  $P[X_1 = x_1, \dots, X_n = x_n | T = t]$ 가  $\theta$ 와 무관한 경우에 통계량  $T$ 는  $\theta$ 의 충분 통계량이라고 한다.

<예 6.6-4>  $X_1, X_2, \dots, X_n$ 을 베르누이 시행  $B(1, p)$ 에서의 확률표본이라 하자.  $P(X_i = \text{성공}) = p$ 이고,  $P(X_i = \text{실패}) = 1 - p$ 이다. 이제  $Y = \sum X_i$ 라 두면

$$\begin{aligned} P[X_1 = x_1, \dots, X_n = x_n | Y = y] &= \frac{P[X_1 = x_1, \dots, X_n = x_n, Y = y]}{P[Y = y]} \\ &= \frac{p^y(1-p)^{n-y}}{\binom{n}{y} p^y(1-p)^{n-y}} = \frac{1}{\binom{n}{y}} \end{aligned}$$

이므로  $p$ 와는 무관하다. 따라서  $Y = \sum X_i$ 는  $p$ 의 충분 통계량이다.

[참고] ①  $P[X_1 = x_1, \dots, X_n = x_n | X_1 = x_1, \dots, X_n = x_n] = 1$ 이므로 모수  $\theta$

와는 무관하다. 즉, 확률표본 자체는  $\theta$ 의 충분 통계량이다.

②  $Y_1, \dots, Y_n$ 을  $X_1, \dots, X_n$ 의 순서 통계량이라고 하자.

$$P[X_1 = x_1, \dots, X_n = x_n | Y_1 = y_1, \dots, Y_n = y_n] = \frac{1}{n!}$$

이므로 모수  $\theta$ 와는 무관하다. 따라서 순서 통계량은  $\theta$ 의 충분 통계량이다.

<예 6.6-5>  $X_1, X_2$ 는 밀도함수가  $f(x; \lambda) = \frac{\lambda^x e^{-\lambda}}{x!}$ ,  $x = 0, 1, \dots$ 인 포아송 분포에서의 확률표본이라고 하자.  $X_1 - X_2$ 는  $\lambda$ 의 충분 통계량인가?

<풀이>  $P[X_1 = 0, X_2 = 0 | X_1 - X_2 = 0] = P[X_1 = 0, X_2 = 0 | X_1 = X_2]$

$$= \frac{P[X_1 = 0, X_2 = 0, X_1 = X_2]}{P[X_1 = X_2]} = \frac{P[X_1 = 0, X_2 = 0]}{P[X_1 = X_2]}$$

$$\langle P[X_1 = X_2] = \sum_{k=0}^{\infty} P[X_1 = k, X_2 = k] = \sum_{k=0}^{\infty} P[X_1 = k] P[X_2 = k]$$

$$= \sum_{k=0}^{\infty} \left( e^{-\lambda} \frac{\lambda^k}{k!} \right)^2 = e^{-2\lambda} \left[ 1 + \lambda^2 + \left( \frac{\lambda^2}{2!} \right)^2 + \dots \right] \text{이므로} \rangle$$

$$= \frac{(f(0; \lambda))^2}{\sum_{k=0}^{\infty} (f(k; \lambda))^2} = \frac{e^{-2\lambda}}{e^{-2\lambda} \left[ 1 + \lambda^2 + \left( \frac{\lambda^2}{2!} \right)^2 + \dots \right]} = \frac{1}{1 + \lambda^2 + \left( \frac{\lambda^2}{2!} \right)^2 + \left( \frac{\lambda^3}{3!} \right)^2 + \dots}$$

이므로  $\lambda$ 가 포함되어 있다. 따라서,  $X_1 - X_2$ 는  $\lambda$ 의 충분 통계량이 될 수 없다.

<정리 6.6-2> 피셔-네이만의 인수분해 정리 (Fisher-Neyman's factorization theorem))

$U$ 가 확률표본  $X_1, X_2, \dots, X_n$ 으로 만들어진 통계량이라고 할 때,  $U$ 가 모수  $\theta$ 의 충분 통계량이 될 필요충분조건은 우도함수가 다음과 같이 인수분해되는 것이다.

$$L(\theta; x_1, \dots, x_n) = g(u; \theta) \cdot h(x_1, \dots, x_n).$$

<예 6.6-6>  $X_1, \dots, X_n$ 는 밀도함수가  $f(x; p) = p^x(1-p)$ ,  $x = 0, 1, \dots$ 인 기하분포에서의 확률표본이라고 하면 우도함수는

$$L(p; x_1, \dots, x_n) = p^{\sum x_i} (1-p)^n$$

이 된다.  $u = \sum x_i$ 이라 하고  $g(u, p) = p^u(1-p)^n$ ,  $h(x_1, \dots, x_n) = 1$ 로 두면 위의 우도함수는  $g(u, \theta)$ 와  $h(x_1, \dots, x_n)$ 의 곱으로 인수분해된다. 따라서  $U = \sum X_i$ 는  $\theta$ 의 충분 통계량이 된다.

<예 6.6-7>  $X_1, \dots, X_n$ 을 정규분포  $N(0, \sigma^2)$ 에서의 확률표본이라고 하고,  $\theta = \sigma^2$ 으로 두면 우도함수는

$$L(\theta; x_1, \dots, x_n) = \left( \frac{1}{\sqrt{2\pi\theta}} \right)^n \exp\left(-\frac{1}{2\theta} \sum x_i^2\right)$$

이다.  $u = \sum x_i^2$ 이라 하고  $g(u, \theta) = \left( \frac{1}{\sqrt{2\pi\theta}} \right)^n \exp\left(-\frac{1}{2\theta} \sum x_i^2\right)$ ,  $h(x_1, \dots, x_n) = 1$ 로 두면 위의 우도함수는  $g(u, \theta)$ 와  $h(x_1, \dots, x_n)$ 의 곱으로 인수분해된다. 따라서  $U = \sum X_i^2$ 는  $\theta$ 의 충분 통계량이 된다.

<예 6.6-8>  $X_1, \dots, X_n$ 을 균일분포  $u(0, \theta)$ 에서의 확률표본이라고 하면 우도함수

$$L(\theta; x_1, \dots, x_n) = \begin{cases} \frac{1}{\theta^n}, & 0 \leq x_{(n)} \leq \theta \\ 0, & \text{그 외} \end{cases}$$

이 된다.  $u = x_{(n)}$ 이라고 하면 위의 우도함수는

$$g(u; \theta) = \begin{cases} \frac{1}{\theta^n}, & 0 \leq x_{(n)} \leq \theta \\ 0, & \text{그 외} \end{cases}$$

와  $h(x_1, \dots, x_n) = 1$ 의 곱으로 인수분해된다. 따라서  $U = X_{(n)}$ 는  $\theta$ 의 충분 통계량

[참고] 위의 인수분해정리와 최우(최대가능도) 추정량의 정의로부터 최우 추정량은 충분 통계량의 함수로 주어짐을 알 수 있다.



<따름정리> 정리 6.6-1의 따름정리

$E(U)=\theta$ 이고, 통계량  $T$ 가  $\theta$ 의 충분 통계량이면  $W=E[U|T]$ 는 충분 통계량의 함수로 주어지며  $\theta$ 의 불편 추정량이 되고  $W$ 의 분산은  $U$ 의 분산보다 크지 않다. 즉,  $Var(W) \leq Var(U)$ 이다.

<예 6.6-9>  $X_1, \dots, X_n$ 을 서로 독립인 베르누이 시행  $B(1, p)$ 에서의 확률표본이라고 하면  $\sum X_i$ 는  $p$ 의 충분 통계량이고  $E(X_1)=p$ 이므로  $U=X_1$ ,  $T=\sum X_i$ 라 두면 위의 따름정리로부터  $E[U|T]$ 는  $T$ 의 함수이며  $p$ 의 불편추정량이다.

$$\begin{aligned} E\left[X_1 \mid \sum_{i=1}^n X_i = y\right] &= \sum_{x_1=0}^1 x_1 \cdot P\left[X_1 = x_1 \mid \sum_{i=1}^n X_i = y\right] = 1 \cdot P\left[X_1 = 1 \mid \sum_{i=1}^n X_i = y\right] \\ &= \frac{P\left[X_1 = 1, \sum_{i=1}^n X_i = y\right]}{P\left[\sum_{i=1}^n X_i = y\right]} = \frac{P\left[X_1 = 1, \sum_{i=2}^n X_i = y-1\right]}{P\left[\sum_{i=1}^n X_i = y\right]} \\ &= \frac{p \cdot \binom{n-1}{y-1} p^{y-1} (1-p)^{n-1-y+1}}{\binom{n}{y} p^y (1-p)^{n-y}} \\ &= \frac{\binom{n-1}{y-1}}{\binom{n}{y}} = \frac{y}{n} = \sum \frac{X_i}{n} = \bar{X}. \end{aligned}$$

또한  $\sum X_i$ 의 분포는  $B(n, p)$ 이므로  $E(\bar{X})=p$ ,  $Var(\bar{X})=\frac{p(1-p)}{n}$ 이다. 앞의 따름정리에 따라서  $U=\bar{X}$ ,  $T=\sum X_i$ 라 두면

$$E[\bar{X} \mid \sum X_i = y] = E\left[\frac{1}{n} \sum X_i \mid \sum X_i = y\right] = \frac{y}{n}$$

임을 알 수 있다. 따라서  $Var(\bar{X})=\frac{p(1-p)}{n} \leq p(1-p)=Var(X_1)$ 이므로  $\bar{X}$ 는  $p$ 의 최소분산 불편추정량임을 알 수 있다.

<예 6.6-10>  $X_1, \dots, X_n$ 을 균일분포  $U(0, \theta)$ 에서의 확률표본이라고 하면  $X_{(n)}$ 은  $\theta$ 의 충분 통계량이고,

$E[X_{(n)}]=\frac{n}{n+1}\theta$ 이므로  $\frac{n+1}{n}X_{(n)}$ 는  $\theta$ 의 불편 추정량이다.

$$E\left[\frac{n+1}{n}X_{(n)} \mid X_{(n)} = y\right] = \frac{n+1}{n}y$$

이므로  $\frac{n+1}{n}X_{(n)}$ 는  $\theta$ 의 최소분산 불편추정량이 된다.

<정리 6.6-3> 크레이머-라오의 하한 (cramer-Rao lower bound; CRLB)

$X_1, \dots, X_n$ 은 밀도함수가  $f(x: \theta)$ 인 분포에서의 확률표본이라 하고 모수  $\theta$ 는  $\theta \in \Omega = \{\theta: c < \theta < d\}$ 인 관계가 있으며  $c$ 와  $d$ 는  $\theta$ 에 무관하다고 하자.  $\frac{\partial}{\partial \theta} \ln f(x: \theta)$ 의 값이 존재하면  $\theta$ 의 불편 추정량  $U$ 에 대하여 다음의 부등식이 성립한다.

$$\text{Var}(U) \geq \frac{1}{I(\theta)}.$$

여기서  $I(\theta)$ 는 피셔의 정보량 (Fisher's information)

$$I(\theta) = nE\left[\left(\frac{\partial}{\partial \theta} \ln f(x: \theta)\right)^2\right] = -nE\left[\frac{\partial^2}{\partial \theta^2} \ln f(x: \theta)\right]$$

• 모수  $\theta$ 의 불편 추정량  $T$ 의 분산이  $\frac{1}{I(\theta)}$ (=CRLB)와 같다면 추정량  $T$ 는 최소분산 불편추정량(MVUE)이 된다. 피셔의 정보량  $I(\theta)$ 는 표본의 크기가 클수록 증가하고 분산이 클수록 감소한다.

<예 6.6-11>  $X_1, \dots, X_n$ 을 밀도함수가  $f(x: p) = p^x(1-p)^{1-x}$ ,  $x = 0, 1$ 인 베르누이 시행  $B(1, p)$ 에서의 확률표본이라고 하자. 표본 평균  $\bar{X}$ 의 CRLB를 구해보자

$$\begin{aligned} \frac{\partial}{\partial p} \ln f(x: p) &= \frac{\partial}{\partial p} (x \ln p + (1-x) \ln(1-p)) = \frac{x}{p} - \frac{1-x}{1-p}, \quad \frac{\partial^2}{\partial p^2} \ln f(x: p) = -\frac{x}{p^2} - \frac{1-x}{(1-p)^2} \\ &= -\frac{1}{(1-p)^2} - \left(\frac{1}{p^2} - \frac{1}{(1-p)^2}\right)x \quad \text{이므로 } E(X) = p \text{이므로} \end{aligned}$$

$$E\left[\frac{\partial^2}{\partial p^2} \ln f(x: p)\right] = -\frac{1}{(1-p)^2} - \left(\frac{1}{p^2} - \frac{1}{(1-p)^2}\right)p = -\frac{1}{p(1-p)} \text{이다.}$$

따라서  $I(p) = \frac{n}{p(1-p)}$ 이고  $CRLB = \frac{p(1-p)}{n}$ 이다. 한편

$$\text{Var}(\bar{X}) = \frac{p(1-p)}{n} = \frac{1}{I(p)} \text{이므로 } \bar{X} \text{는 } p \text{의 MVUE가 된다.}$$

<예 6.6-12>  $X_1, X_2, \dots, X_n$ 을 정규분포  $N(\theta, 1)$ 에서의 확률표본이라고 할 때,  $\theta$ 의 MVUE를 구하도록 한다.

$$\frac{\partial}{\partial \theta} \ln f(x: \theta) = \frac{\partial}{\partial \theta} \ln \left[ \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(x-\theta)^2\right) \right] = \frac{\partial}{\partial \theta} \left( -\frac{1}{2}(x-\theta)^2 \right) = x - \theta,$$

$$\frac{\partial^2}{\partial \theta^2} \ln f(x: \theta) = \frac{\partial}{\partial \theta} (x - \theta) = -1$$

이므로 피셔의 정보량  $I(\theta)$ 는 다음과 같이 얻어진다.

$$I(\theta) = -nE\left(\frac{\partial^2}{\partial \theta^2} \ln f(x: \theta)\right) = -nE(-1) = n.$$

따라서  $\theta$ 의 CRLB는  $\frac{1}{n}$ 이며,  $\text{Var}(\bar{X}) = \frac{1}{n} = CRLB$ 이므로  $\bar{X}$ 는  $\theta$ 의 MVUE가 된다.

<예 6.6-13>  $X_1, X_2, \dots, X_n$ 을 정규분포  $N(0, \sigma^2)$ 에서의 확률표본이라고 할 때,  $\theta = \sigma^2$ 의 MVUE를 구해보자

$$\begin{aligned}\frac{\partial}{\partial \theta} \ln f(x; \theta) &= \frac{\partial}{\partial \theta} \ln \left[ \frac{1}{\sqrt{2\pi\theta}} \exp \left( -\frac{1}{2} \frac{x^2}{\theta} \right) \right] \\ &= \frac{\partial}{\partial \theta} \left[ -\frac{1}{2} \ln(2\pi\theta) - \frac{1}{2} \frac{x^2}{\theta} \right] \\ &= -\frac{1}{2\theta} + \frac{x^2}{2\theta^2}, \\ \frac{\partial^2}{\partial \theta^2} \ln f(x; \theta) &= \frac{\partial^2}{\partial \theta^2} \left( -\frac{1}{2\theta} + \frac{x^2}{2\theta^2} \right)' = \frac{1}{2\theta^2} - \frac{x^2}{\theta^3}, \\ \therefore E \left[ \frac{\partial^2}{\partial \theta^2} \ln f(x; \theta) \right] &= \frac{1}{2\theta^2} - \frac{1}{\theta^3} E(X^2) \\ &= \frac{1}{2\theta^2} - \frac{1}{\theta^3} \cdot \theta = -\frac{1}{2\theta^2}, \\ I(\theta) &= -nE \left[ \frac{\partial^2}{\partial \theta^2} \ln f(x; \theta) \right] = \frac{n}{2\theta^2}.\end{aligned}$$

따라서  $\theta$ 의 CRLB는  $\frac{2\theta^2}{n} = \frac{2\sigma^4}{n}$ 이다. 한편  $\hat{\sigma}^2 = \frac{1}{n} \sum X_i^2$ 로 두면  $E(X_i^2) = \sigma^2$ 이므로

$$E(\hat{\sigma}^2) = E \left[ \frac{1}{n} \sum X_i^2 \right] = \frac{1}{n} \sum E(X_i^2) = \sigma^2$$

즉,  $\hat{\sigma}^2$ 는  $\sigma^2$ 의 불편 추정량이다. 또한  $X_i$ 의 분포가  $N(0, \sigma^2)$ 이므로  $\frac{X_i^2}{\sigma^2}$ 의 분포는  $\chi^2(1)$ 이다. 따라서  $Var \left( \frac{X_i^2}{\sigma^2} \right) = 2$ ,  $Var(X_i^2) = 2\sigma^4$ 이다.

$$\therefore Var(\hat{\sigma}^2) = Var \left( \frac{1}{n} \sum X_i^2 \right) = \frac{1}{n^2} \sum Var(X_i^2) = \frac{2\sigma^4}{n} = CRLB.$$

그러므로  $\hat{\sigma}^2 = \frac{1}{n} \sum X_i^2$ 는  $\sigma^2$ 의 MVUE가 된다.

## 7. 추정량의 기타 성질

$X$ : 동전을  $n$ 회 독립적으로 던지는 실험에서 앞면이 나오는 회수

$p$ : 앞면이 나오는 비율,  $p$ 의 추정량  $\frac{X}{n}$ 의 분산  $\frac{p(1-p)}{n} (:= h(p))$ 의 추정량

$Z = h\left(\frac{X}{n}\right) = \frac{X}{n}\left(1 - \frac{X}{n}\right)/n$ 으로 두면

$$\begin{aligned} E(Z) &= E\left\{\frac{X}{n}\left(1 - \frac{X}{n}\right)/n\right\} = \frac{1}{n^3} E(nX - X^2) \\ &= \frac{1}{n^3} \{nE(X) - E(X^2)\} \\ &= \frac{1}{n^3} \{n \cdot np - \{(np)^2 + np(1-p)\}\} \\ &= \frac{1}{n^2} (n-1)p(1-p) = \frac{n-1}{n} \frac{p(1-p)}{n} \end{aligned}$$

이므로  $Z$ 는  $h(p) = \frac{p(1-p)}{n}$ 의 편의 추정량이다. 표현을 바꾸면  $\frac{n}{n-1}Z = \frac{n}{n-1}h\left(\frac{X}{n}\right)$ 은  $h(p)$ 의 불편 추정량이 된다.

<정리 6.7-1>  $h(\theta)$ 가  $\theta$ 의 연속 함수이고  $\hat{\theta}$ 가  $\theta$ 의 일치 추정량일 때,  $h(\hat{\theta})$ 는  $h(\theta)$ 의 일치 추정량이 된다.

<증명> 연속함수의 정의 (임의의  $\epsilon > 0$ 에 대하여  $|\hat{\theta} - \theta| < \delta$ 에 따라서  $|h(\hat{\theta}) - h(\theta)| < \epsilon$ 이 되는  $\delta > 0$ 이 존재한다.)에 의하여

$$P[|\hat{\theta} - \theta| < \delta] \leq P[|h(\hat{\theta}) - h(\theta)| < \epsilon]$$

이 성립하는데  $\hat{\theta}$ 이  $\theta$ 의 일치 추정량이므로  $P[|\hat{\theta} - \theta| < \delta] = 1$ 이다. 따라서  $P[|h(\hat{\theta}) - h(\theta)| < \epsilon] = 1$ 이 성립한다. 즉  $h(\hat{\theta})$ 는  $h(\theta)$ 의 일치 추정량이 된다.

<예 6.7-1> 확률변수  $X$ 의 분포가 정규분포  $N(\mu, \sigma^2)$ 일 때,  $P[c < X]$ 의 일치 추정량을 구해보자.

$$P[c < X] = P\left[\frac{c - \mu}{\sigma} < \frac{X - \mu}{\sigma}\right] = 1 - \Phi\left(\frac{c - \mu}{\sigma}\right)$$

이며  $\mu$ 와  $\sigma^2$ 이 미지의 모수이면  $\mu$ 의 최우 추정량  $\hat{\mu} = \bar{X}$ 와  $\sigma^2$ 의 최우추정량  $\hat{\sigma}^2 = S^2$ 을 사용하여

$$Z = 1 - \Phi\left(\frac{c - \bar{X}}{S}\right)$$

가  $P[c < X]$ 의 일치 추정량이 된다.

[참고]  $T = \frac{\bar{X} - c}{S/\sqrt{n-1}} = \frac{\sqrt{n}(\bar{X} - c)/\sigma}{\sqrt{\sum(X_i - \bar{X})^2/(n-1)\sigma^2}}$ 는 자유도가  $n-1$ 인 t-분포  $t(n-1)$ 을 하는 데  $c \neq \mu$ 인 경우에  $T$ 는 비중심 t-분포 (Noncentral t-distribution)를 한다고 한다.

<예 6.7-2> 확률변수  $X$ 의 분포가 정규분포  $N(\mu_X, \sigma^2)$ 이고 확률변수  $Y$ 의 분포가  $N(\mu_Y, \sigma^2)$ 이며  $X$ 와  $Y$ 가 서로 독립이고  $\sigma^2$ 을 모르고 있을 때,  $P[X < Y]$ 의 일치 추정량을 구해보자.

<풀이>  $X - Y$ 의 분포는  $N(\mu_X - \mu_Y, 2\sigma^2)$ 이므로

$$P[X < Y] = P[X - Y < 0] = P\left[\frac{X - Y - (\mu_X - \mu_Y)}{\sqrt{2}\sigma} < \frac{\mu_Y - \mu_X}{\sqrt{2}\sigma}\right]$$

이다. 이제  $X_1, \dots, X_m$ 을 정규분포  $N(\mu_X, \sigma^2)$ 에서의 확률표본이라 하고  $Y_1, \dots, Y_n$ 을 정규분포  $N(\mu_Y, \sigma^2)$ 에서의 확률표본이라 하면 우도함수는

$$L(\mu_X, \mu_Y, \sigma^2) = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{m+n}{2}} \exp\left[-\frac{\sum_{i=1}^m (X_i - \mu_X)^2 + \sum_{i=1}^n (Y_i - \mu_Y)^2}{2\sigma^2}\right]$$

이 된다. 이제 최우 추정량  $\hat{\mu}_X = \bar{X}$ ,  $\hat{\mu}_Y = \bar{Y}$ ,  $\hat{\sigma}^2 = \frac{mS_X^2 + nS_Y^2}{m+n}$ 을 사용하면  $P[X < Y]$ 의 일치 추정량은  $\Phi(cT)$ 의 형태로 표현되며  $c$ 와  $T$ 는 아래와 같다.

$$c = \sqrt{\frac{(m+n)^2}{2mn(m+n-2)}} \quad , \quad T = \frac{\bar{Y} - \bar{X}}{\sqrt{\frac{mS_X^2 + nS_Y^2}{m+n-2} \left( \frac{1}{m} + \frac{1}{n} \right)}} \quad .$$

※  $T$ 는 자유도가  $m+n-2$ 인 t-분포를 따른다.